

9. 1. 19

first fit

2035 + 1278

first - previous slide

new file (R) add pr new file class will return same as

0.75468 k-10,000 10k 1000 will

(hth file) new file new file PMK predict predict predict

first few

Feature engineering -

new file first few features same as -

new file will, not the model from previous slide

14 -> pr 15 -> 14 new k-1000 will

. new file feature from

will & c, y from -

y - s new file / 11 new file y from -

y - s new file " " " " " 1000 -

y - s new file 11 new file 1/5 prk predict will -

1000 1000 (1000 1000 1000 1000 1000)

PMK predict new file predict

linear model -

L2, L1 regularize pr predict not 1000 -

1000 1000 1000

new file L1 L2 pr predict 1000 -

train -> R 10 fold CV 1000 prk 1/5

1/5 prk recall, 1000 1000 1000 1000 data

(new file prk 1000 1000 1000 1000 1000)

: KNN

new file prk 1000 1000 1000 1000 1000 -

new file 1000 1000 cosine similarity 1000

K -> new file 1000 1000 1000 1000 1000 -

11

9.1.19

42

(112NNW 113111) 10-Fold-CV 1113'N 82'W

: Boosting -

1113, Boosting σ P'IN γ 112NNW 1113'N 82'W -

1113'N 82'W gradient boosting 1113'N 82'W

light gradient boosting per P'IN 1113'N 82'W

1113'N 82'W 1113'N 82'W

: linear models -

1113'N 82'W P'IN 1113'N 82'W 1113'N 82'W -

P'IN 1113'N 82'W 1113'N 82'W P'IN 1113'N 82'W

As function L1 Lasso P'IN 1113'N 82'W Lasso

(P'IN) 1113'N 82'W

from 11 1113'N 82'W 1113'N 82'W P'IN 1113'N 82'W -

P'IN 1113'N 82'W 1113'N 82'W P'IN 1113'N 82'W -

1113'N 82'W 1113'N 82'W P'IN 1113'N 82'W P'IN 1113'N 82'W

L1 Lasso L1 P'IN 1113'N 82'W Lasso P'IN 1113'N 82'W

Variance -1 P'IN 1113'N 82'W

: KNN -

1113'N 82'W 1113'N 82'W 1113'N 82'W 1113'N 82'W -

P'IN 1113'N 82'W 1113'N 82'W 1113'N 82'W 1113'N 82'W

1113'N 82'W 1113'N 82'W 1113'N 82'W 1113'N 82'W

1113'N 82'W Data 1113'N 82'W 1113'N 82'W P'IN 1113'N 82'W

1113'N 82'W cosine 1113'N 82'W P'IN 1113'N 82'W

5 1113'N 82'W 1113'N 82'W 1113'N 82'W 1113'N 82'W

1 Similarity 1113'N 82'W 1113'N 82'W 1113'N 82'W

.1113'N 82'W 1113'N 82'W 1113'N 82'W

: Boosting -

(1113'N 82'W 1113'N 82'W 1113'N 82'W 1113'N 82'W -

1113'N 82'W 1113'N 82'W 1113'N 82'W 1113'N 82'W

41

ר' ו' ג' פ' מ' ס'

ל' ו' פ' מ' ס' מ' ס' מ' ס' מ' ס' מ' ס'

ר' ו' ג' פ' מ' ס' מ' ס' מ' ס' מ' ס' מ' ס'

ל' ו' פ' מ' ס' מ' ס' מ' ס' מ' ס' מ' ס'

ר' ו' ג' פ' מ' ס' מ' ס' מ' ס' מ' ס' מ' ס'

ל' ו' ג' פ' מ' ס'

ל' ו' ג' פ' מ' ס' מ' ס' מ' ס' מ' ס' מ' ס'

ר' ו' ג' פ' מ' ס' מ' ס' מ' ס' מ' ס' מ' ס'

ל' ו' ג' פ' מ' ס' מ' ס' מ' ס' מ' ס' מ' ס'

ל' ו' ג' פ' מ' ס' מ' ס' מ' ס' מ' ס'

ל' ו' ג' פ' מ' ס' מ' ס' מ' ס' מ' ס' מ' ס'

ר' ו' ג' פ' מ' ס' מ' ס' מ' ס' מ' ס' מ' ס'

ר' ו' ג' פ' מ' ס' מ' ס' מ' ס' מ' ס' מ' ס'

ל' ו' ג' פ' מ' ס' מ' ס' מ' ס' מ' ס' מ' ס'

ר' ו' ג' פ' מ' ס' מ' ס' מ' ס' מ' ס' מ' ס'

ל' ו' ג' פ' מ' ס' מ' ס' מ' ס' מ' ס' מ' ס'

ר' ו' ג' פ' מ' ס' מ' ס' מ' ס' מ' ס' מ' ס'

(1gb -> ו' ג' פ' מ' ס' מ' ס' מ' ס' מ' ס'

ר' ו' ג' פ' מ' ס' מ' ס' מ' ס' מ' ס' מ' ס'

ר' ו' ג' פ' מ' ס' מ' ס' מ' ס' מ' ס' מ' ס'

ר' ו' ג' פ' מ' ס' מ' ס' מ' ס' מ' ס' מ' ס'

ר' ו' ג' פ' מ' ס' מ' ס' מ' ס' מ' ס' מ' ס'

ר' ו' ג' פ' מ' ס' מ' ס' מ' ס' מ' ס' מ' ס'

ר' ו' ג' פ' מ' ס' מ' ס' מ' ס' מ' ס' מ' ס'

ר' ו' ג' פ' מ' ס' מ' ס' מ' ס' מ' ס' מ' ס'

. Boosting -> פ' מ' ס' מ' ס' מ' ס' מ' ס'

רִזְקוֹן

אנו מגדירים (פונקציית פלט נetz) כונפלקסית כפלה נטול שיטות
 פונקציית פלט נetz היא פונקציית פלט נetz המבוססת על רשת
 דו-방향ית (Bi-directional RNN).
 רשת דו-방향ית מוגדרת כרשת נetz שפונה מימין לשמאל ומשמאל
 למימין, כלומר פונקציית פלט נetz היא פונקציית פלט נetz המבוססת על רשת דו-방향ית.
 ב-Back Propagation-through-time (BPTT) מוגדרת פונקציית פלט נetz כפונקציית פלט נetz המבוססת על רשת דו-방향ית.
 פונקציית פלט נetz המבוססת על רשת דו-방향ית מוגדרת כפונקציית פלט נetz המבוססת על רשת דו-방향ית.
 פונקציית פלט נetz המבוססת על רשת דו-방향ית מוגדרת כפונקציית פלט נetz המבוססת על רשת דו-방향ית.
 פונקציית פלט נetz המבוססת על רשת דו-방향ית מוגדרת כפונקציית פלט נetz המבוססת על רשת דו-방향ית.
 פונקציית פלט נetz המבוססת על רשת דו-방향ית מוגדרת כפונקציית פלט נetz המבוססת על רשת דו-방향ית.

11.1.19

OPTION (2) !

וְנִזְמַן זֵיתָן / MNIST
לְרֹא אֶל מִינְטָרְפָּה
'פְּרָטָרְפָּה' תְּרָמָה
SVM -

לְזֵיתָן כְּלָב יְגַדְּלָה וְאֶל מִינְטָרְפָּה
לְזֵיתָן כְּלָב יְגַדְּלָה CNN -

לְזֵיתָן כְּלָב פְּרָטָרְפָּה וְאֶל מִינְטָרְפָּה סְסָמָה
לְזֵיתָן פְּרָטָרְפָּה סְסָמָה

פְּרָטָרְפָּה פְּרָטָרְפָּה וְאֶל מִינְטָרְפָּה פְּרָטָרְפָּה סְסָמָה -
tol / ε = 0.001 -

One vs rest -

$$\text{gamma} = \frac{1}{n\text{-Features}}$$

לְזֵיתָן מִינְטָרְפָּה SVM ->, נִזְמַן מִינְטָרְפָּה מִינְטָרְפָּה
לְזֵיתָן test -> כְּלָב 94.2% כְּלָב 94.2%

. Overfitting מִינְטָרְפָּה כְּלָב train -> כְּלָב 99.2%

לְזֵיתָן מִינְטָרְפָּה confusion matrix -> כְּלָב מִינְטָרְפָּה

לְזֵיתָן מִינְטָרְפָּה מִינְטָרְפָּה מִינְטָרְפָּה כְּלָב
.3 מִינְטָרְפָּה כְּלָב מִינְטָרְפָּה

(1) מִינְטָרְפָּה מִינְטָרְפָּה מִינְטָרְפָּה מִינְטָרְפָּה
(.1) מִינְטָרְפָּה מִינְטָרְפָּה מִינְטָרְפָּה מִינְטָרְפָּה

לְזֵיתָן כְּלָב מִינְטָרְפָּה מִינְטָרְפָּה CNN -

לְזֵיתָן מִינְטָרְפָּה מִינְטָרְפָּה מִינְטָרְפָּה מִינְטָרְפָּה CNN -

לְזֵיתָן מִינְטָרְפָּה מִינְטָרְפָּה מִינְטָרְפָּה CNN -

לְזֵיתָן מִינְטָרְפָּה CNN -

(5)

2. 1. 14

input	hidden layer	out put
0	0	0
0	0	0
0	:	0
:	:	0
0	0	0
:	:	0
0	0	0
256	3500	3

⇒ output layer relu A Activation function ReLU
softmax

softmax loss function \rightarrow loss function mean square error

ReLU loss function \rightarrow 93.7% loss value test \rightarrow

overfitting \rightarrow weight decay

Learning rate and weight decay \rightarrow CNN -
hyperparameter tuning weight decay learning rate weight decay learning rate

! weight

input \rightarrow conv2D \rightarrow relu \rightarrow conv2D \rightarrow relu \rightarrow max pool \rightarrow

\rightarrow Dropout (0.25) \rightarrow conv2D \rightarrow relu \rightarrow conv2D \rightarrow relu \rightarrow max pool

\rightarrow Dropout (0.25) \rightarrow flatten \rightarrow Dense \rightarrow Dropout (0.5)

\rightarrow Dense \rightarrow softmax

initialization \rightarrow many ways \rightarrow He initialization \rightarrow random uniform

regularization \rightarrow L2, RMSprop \rightarrow momentum \rightarrow learning rate \rightarrow learning rate decay, learning rate drop, learning rate annealing

minibatch \rightarrow mini batch size \rightarrow learning rate \rightarrow learning rate drop, learning rate annealing, learning rate decay

padding \rightarrow augmentation \rightarrow crop, padding (6)

מ. 1. 19

22

92.4% train \rightarrow פָּרָסָה יְהוָה מֶלֶךְ יִשְׂרָאֵל
100% test . 98.09% fest \rightarrow פָּרָסָה מֶלֶךְ יִשְׂרָאֵל
100% confusion matrix confusion \rightarrow פָּרָסָה
3 1% ANNA 5 1%

MNIST dataset 10000 images 784x28x28
10000 images one hot vec \rightarrow 10000x10000 P.A.
0:2 , 1:3 2:5
MNIST 10000 images 784x28x28
0.01 1.1%

!!! MNIST 10000 images 784x28x28 -

10000 images 784x28x28 10000x10000 P.A. -
MNIST 10000 images 784x28x28 10000x10000 P.A.
test -> overfitting 10000

10000 images 784x28x28 10000x10000 P.A. -
MNIST 10000 images 784x28x28 10000x10000 P.A.
10000 images 784x28x28 10000x10000 P.A.

epoch \rightarrow 10000 images 784x28x28 10000x10000 P.A. -

MNIST 10000 images 784x28x28 10000x10000 P.A.
10000 images 784x28x28 10000x10000 P.A.

MNIST 10000 images 784x28x28 10000x10000 P.A. -
10000 images 784x28x28 10000x10000 P.A.

GD / Adam \rightarrow 10000 images 784x28x28 10000x10000 P.A. -

(more MNIST images) 10000 images 784x28x28 10000x10000 P.A. -

DA \rightarrow Augmentation 10000 images 784x28x28 10000x10000 P.A. -

DropOut \rightarrow 10000 images 784x28x28 10000x10000 P.A. -

(+)

From prior knowledge, prior probability, prior for x.i
: $\hat{y} = \text{prior } x_i + \text{prior } \hat{y}_i$

Model Selection

For each feature, we can calculate the prior probability -

Model variance / overfitting measure which is the prior probability

Model selection is prior probability of each model (prior)

Balance Data - 1. Using prior probability, prior probability of each model -
prior probability of each model selection

Final model - \hat{y}

Predict prior probability of each model is based on domain knowledge
which is prior probability of each model is based on domain knowledge
and prior probability of each model is based on domain knowledge
(prior probability of each model is based on domain knowledge)

: prior probability

Goal is to find prior probability gradient boosting -

prior probability is prior probability . Gradient boosting - 1. Prior probability
prior probability prior probability prior probability prior probability
prior probability prior probability prior probability prior probability prior probability

Surrogate splits - prior probability prior probability prior probability

, prior probability prior probability prior probability prior probability

Model selection 2^{k-1} prior probability prior probability prior probability

(8)

10. 1. 19

MNIN BI MNINVA MIYA REBH IS SFINN PINR
REPINRIS IS REBH JAI ANN BURP FIAF LIFUR
MNINVA MNINVA / UNN Variance -> SFINN BI
Variance) MNC QVIA DIF CUDANLOR DIF MNIN
. BHIS -> MNC BI JAI

� 10% of IN 1.5 (categorical Boosting) catBoost -
. Handey 'y' MNC BCI RFIK OF VYLLA KAVIN
PUPNA YVIA f NICOVII UNI DIF ENAPN IS SFINN
VYNNM MNINVA MNINVA MNINVA DIF YELC PUPNIRCA
. VYNNM IN S DIF YELC REBHN

'PNM WHE PPN
1. PPNM VYNNM OR PUPNAE PUPNA DIF PYYA ; KNN -
VYNNM WHE PPNM VYNNM (UNN PUPN VYNNM PPN)
PUPNIRCA (PUPN VYNNM PPNM VYNNM VYNNM + UNN, IS PPN
VYNNM MNIN JAI 'D' SNTS PPNM VYNNM PUPNIRCA
VYNNM PPN) JAI (VYNNM VYNNM DIF VYNNM PUPNIRCA
PPN PYYA VYNNM DIF, PPN PUPNIRCA PUPN DIF X JI
. VYNNM VYNNM PPN VYNNM VYNNM PPN)

VYNNM VYNNM VYNNM VYNNM VYNNM VYNNM VYNNM -
VYNNM VYNNM VYNNM VYNNM VYNNM VYNNM VYNNM -
VYNNM VYNNM VYNNM VYNNM VYNNM VYNNM VYNNM -
. VYNNM VYNNM VYNNM VYNNM VYNNM VYNNM VYNNM -
VYNNM VYNNM VYNNM VYNNM VYNNM VYNNM VYNNM -

QFINA MNIN MNIN MNIN PPN - gradient Boosting -
IN PPN MNIN -
(1)

三

לעומת פונקציית האפס הינה פונקציית נזק מינימלית

פונקציית האפס של מילר (Miller) מינימיזה אפס

הו, שנותן מינימום אחד, ופונקציית האפס מינימלית

הו, שנותן מינימום אחד, (Fully connected, CRNN, RNN)

($K \geq 2$ וינט סופטמאר | $K=2$ וינט סיגנומיד)

(cross entropy loss) מינימיזציה דואלה כפנית

לכליות מינימום של מילר מינימיזציה דואלה כפנית

הו, מינימיזציה דואלה כפנית מינימום אחד

הו, מילר מינימיזציה דואלה כפנית מינימום אחד

הו, מילר מינימיזציה דואלה כפנית מינימום אחד

. (מודולר) מינימיזציה דואלה כפנית מינימום אחד

לפונקציית האפס SVM או kernel machines -

פונקציית האפס מינימיזציה דואלה כפנית מינימום אחד

(מודולר) מינימיזציה דואלה כפנית מינימום אחד

הו, מינימיזציה דואלה כפנית מינימום אחד

הו, מילר מינימיזציה דואלה כפנית מינימום אחד

הו, מילר מינימיזציה דואלה כפנית מינימום אחד

. מילר מינימיזציה דואלה כפנית מינימום אחד

. מילר מינימיזציה דואלה כפנית מינימום אחד

הו, מילר מינימיזציה דואלה כפנית מינימום אחד

הו, מילר מינימיזציה דואלה כפנית מינימום אחד

הו, מילר מינימיזציה דואלה כפנית מינימום אחד

. מילר מינימיזציה דואלה כפנית מינימום אחד

. פונקציית האפס מינימיזציה דואלה כפנית מינימום אחד

. (מודולר) מינימיזציה דואלה כפנית מינימום אחד

הו, מילר מינימיזציה דואלה כפנית מינימום אחד

הו, מילר מינימיזציה דואלה כפנית מינימום אחד

הו, מילר מינימיזציה דואלה כפנית מינימום אחד

10.1.14

הה דוחה סדרת תוצאות מודול K מוגדרת
כפונקציית אינטגרציה. קיימת פונקציית אינטגרציה
היא נקראת פונקציית וariance \rightarrow שה
K מוגדרת עליה

הו מודול ליניאר מודול עם נוסחה -
ו-ה פונקציית אינטגרציה היא הינה דוחה מוגדרת
היא נקראת פונקציית וariance. כחישוב
הה פונקציית אינטגרציה היא דוחה מוגדרת פונקציית
פונקציית פונקציית פונקציית דוחה (0-ה פונקציית
הה פונקציית אינטגרציה היא דוחה מוגדרת כ
0.5 מוגדרת Y נקראת S-1 K מוגדרת פונקציית *

פונקציית סיגמא

הה פונקציית סיגמא היא מודול ליניאר מודול -
הה פונקציית סיגמא היא פונקציית אינטגרציה
הה פונקציית סיגמא היא פונקציית וariance
פונקציית אינטגרציה היא דוחה מוגדרת פונקציית
פונקציית סיגמא

פונקציית סיגמא היא דוחה מוגדרת מודול (b)
LDA -

הה פונקציית סיגמא היא מודול ליניאר מודול

$$P(y=g_n | x=x) = \frac{Pr(x=x | y=g_n) \cdot Pr(y=g_n)}{\sum_{k=1}^K Pr(x=x | y=g_k) \cdot Pr(y=g_k)} = \frac{f_n(x) \cdot \bar{\pi}_n}{\sum_{k=1}^K f_k(x) \cdot \bar{\pi}_k}$$

הה פונקציית סיגמא היא מודול ליניאר מודול
 $\sum_{k=1}^K \bar{\pi}_k = 1$ $\Pr(y=g_k) = \bar{\pi}_k$ $f_k(x)$ $\Pr(x=x | y=g_k)$

10. 1. 19

ר'נ

לע'ז יי'ס'ה לאל'ז פ'ר'מ'�'ז א'ל'ז LDA \rightarrow 10.0

$$x | y=g_k \sim N(\mu_k, \Sigma)$$

לע'ז יי'ס'ה 1. יי'ס'ה ס'ז ק' מ'ר'כ'ס'ז ר'ב'ז פ'ר'ז ו'ז'ז
פ'ל'ז ז'ז'

$$\Pr(y=g_k | x) > \Pr(y=g_i | x)$$

לע'ז יי'ס'ה ס'ז ק' מ'ר'כ'ס'ז ר'ב'ז פ'ר'ז ו'ז'ז

$$x^T \lesssim^{-1} [\mu_k - \mu_i] - 0.5 \mu_k^T \Sigma^{-1} \mu_k + 0.5 \mu_i^T \Sigma^{-1} \mu_i - \log\left(\frac{\pi_k}{\pi_i}\right) = 0$$

linear regression -

$$y = \bar{x} \beta + \varepsilon$$

$$\mathbb{E}(\varepsilon) = 0, \text{Var}(\varepsilon) = \sigma^2 I$$

לע'ז יי'ס'ה ס'ז ק' מ'ר'כ'ס'ז ר'ב'ז פ'ר'ז ו'ז'ז

. BLUE פ'ר'ל'ז יי'ס'ה ס'ז ק' מ'ר'כ'ס'ז ר'ב'ז פ'ר'ז ו'ז'ז

; ε_i זי'ז מ'ר'כ'ס'ז ס'ז ק' מ'ר'כ'ס'ז ר'ב'ז פ'ר'ז ו'ז'ז

$$\varepsilon_i \stackrel{iid}{\sim} N(0, \sigma^2)$$

לע'ז יי'ס'ה ס'ז ק' מ'ר'כ'ס'ז ר'ב'ז פ'ר'ז ו'ז'ז

. ע'מ'ג'ז מ'ר'כ'ס'ז ס'ז ק' מ'ר'כ'ס'ז ר'ב'ז פ'ר'ז ו'ז'ז

לע'ז יי'ס'ה ס'ז ק' מ'ר'כ'ס'ז ר'ב'ז פ'ר'ז ו'ז'ז

$$\hat{\beta} \sim N(\beta, (\mathbf{X}^T \mathbf{X})^{-1} \sigma^2)$$

(לע'ז יי'ס'ה) $\hat{\beta}$ כ'ז פ'ר'ל'ז ס'ז ק' מ'ר'כ'ס'ז ר'ב'ז פ'ר'ז ו'ז'ז

linear regression with ridge -

לע'ז יי'ס'ה ס'ז ק' מ'ר'כ'ס'ז ר'ב'ז פ'ר'ז ו'ז'ז

לע'ז יי'ס'ה ס'ז ק' מ'ר'כ'ס'ז ר'ב'ז פ'ר'ז ו'ז'ז

$$y_i \sim N(x_i^T \beta, \sigma^2)$$

(13)

i prior \rightarrow p

$$\beta \sim N(0, \gamma^2 \cdot I)$$

$$\lambda = \frac{6}{\gamma^2} \quad (10\%)$$

mode \rightarrow L1 $\beta(\lambda)$ \rightarrow L1 vector \rightarrow L1 \rightarrow L1

L1, L2, Lasso, ML, L1/L2, Lasso, Ridge, L1

L1 mode \rightarrow L1/L2, Lasso, L1, L1

Ridge \rightarrow L1L2, Lasso, L1, L1

1.100 Lemma ridge

Ridge $\hat{\beta}$ L2 norm β per λ max value y β (a)

$\hat{\beta}_{\text{ridge}}$

$$\hat{\beta}_{\text{ridge}}(\lambda) = (\bar{x}^T \bar{x} + \lambda I)^{-1} \bar{x}^T y$$

(WTF)

$$\hat{y} = \bar{x} \hat{\beta}_{\text{ridge}}(\lambda) = \underbrace{\bar{x} (\bar{x}^T \bar{x} + \lambda I)^{-1} \bar{x}^T y}_{S(\bar{x}, \lambda)} \quad \text{fixed } \bar{x}$$

$$\hat{y} = S(\bar{x}, \lambda) \cdot y$$

147

Permanently λ β $\hat{\beta}(\lambda)$ β $\hat{\beta}(\lambda)$ (b)

Permanently λ $\hat{\beta}(\lambda)$ β $\hat{\beta}(\lambda)$ ridge β

$$\hat{\beta}^{(i)}(\lambda) = \underset{\substack{\beta \\ j \neq i}}{\operatorname{argmin}} \sum_{j=1}^n (y_j - \bar{x}_j^T \beta)^2 + \lambda \sum_{j=1}^p \beta_j^2$$

$$\sum_{\substack{j=1 \\ j \neq i}}^n (y_j - \bar{x}_j^T \hat{\beta}^{(i)}(\lambda))^2 + \lambda \sum_{j=1}^p \hat{\beta}_j^{(i)}(\lambda)^2 = RSS(\lambda)$$

Permanently λ ridge $\hat{\beta}(\lambda)$ β $\hat{\beta}^{(i)}(\lambda)$ β $\hat{\beta}(\lambda)$ β

Permanently λ ridge $\hat{\beta}(\lambda)$ β $\tilde{\beta}(\lambda)$ β $\tilde{\beta}(\lambda)$ β

$$RSS(\hat{\beta}(\lambda)) \leq RSS(\hat{\beta}^{(i)}(\lambda))$$

151

10.1.19

\hat{Y} of $RSS(\hat{\beta}^{(-i)}(\lambda))$ will just do the sum

$$\begin{aligned} \underset{\hat{Y} \text{ of } R}{RSS}(\hat{\beta}^{(-i)}(\lambda)) &= \sum_{j=1}^n [y_j - \underset{j \neq i}{\sum} \hat{\beta}_j^{(-i)} x_j]^2 + [\hat{y}_i^{(-i)} - \underset{j \neq i}{\sum} \hat{\beta}_j^{(-i)} x_j] \\ &\quad \underset{\hat{y}_i = y_i}{=} \hat{y}_i^{(-i)} = y_i \end{aligned}$$

$$\therefore \lambda \leq \sum_{j=1}^p \hat{\beta}_j^{(-i)}$$

$$\begin{aligned} \underset{\hat{Y} \text{ of } R}{RSS}(\hat{\beta}^{(-i)}(\lambda)) &= RSS^{(-i)} + [\hat{y}_i^{(-i)} - \hat{y}_i^{(-i)}]^2 = RSS^{(-i)} \end{aligned}$$

∴ \hat{Y} of $RSS(\hat{\beta}(\lambda))$ is the same as $RSS(\hat{\beta}^{(-i)}(\lambda))$

$$\underset{\hat{Y} \text{ of } R}{RSS}(\hat{\beta}(\lambda)) \leq \underset{\hat{Y} \text{ of } R}{RSS}(\hat{\beta}^{(-i)}(\lambda)) = RSS^{(-i)}$$

$$\begin{aligned} RSS^{(-i)} &\geq RSS(\hat{\beta}(\lambda)) \geq \sum_{j=1}^n (y_j - \underset{j \neq i}{\sum} \hat{\beta}_j(\lambda))^2 \quad \lambda \leq \underset{j=1}{\overset{p}{\sum}} \hat{\beta}_j(\lambda) \\ &\quad \text{Maxima of } n-1 \text{ of } 2021 \end{aligned}$$

$$\sum_{j=1}^n (y_j - \underset{j \neq i}{\sum} \hat{\beta}_j(\lambda))^2 \leq \lambda \leq \sum_{j=1}^p \hat{\beta}_j(\lambda) \geq \sum_{j=1}^n (y_j - \underset{j \neq i}{\sum} \hat{\beta}_j(\lambda))^2 \quad \lambda \leq \underset{j=1}{\overset{p}{\sum}} \hat{\beta}_j(\lambda)$$

∴ $RSS(\hat{\beta}(\lambda)) = \sum_{j=1}^p \hat{\beta}_j(\lambda)^2$ is the sum of squares

train -> predict for i → $n-1$ → 2021 → λ → $\hat{\beta}(\lambda)$

∴ $RSS(\hat{\beta}(\lambda)) = \sum_{j=1}^p \hat{\beta}_j(\lambda)^2$ is the sum of squares

$$\hat{y}_i = \hat{y}_i^{(-i)} + \hat{\beta}_i(\lambda) \quad \hat{Y} = \underset{i=1}{\overset{n}{\sum}} \hat{y}_i^{(-i)} + \hat{\beta}_i(\lambda)$$

(46)

10.1.19

PENALIZED RIDGE LEAST SQUARES POINT
ESTIMATE AND TEST IF YOU PREFER RIDGE OR

1) A NON LINEAR (NON LINEAR) $S(\hat{x}, \lambda)_{ii}$; ASSUME $f(x)$ IS

LINEAR $S(\hat{x}, \lambda)_{ii} = e$ SO $e = \hat{y}_i - \hat{y}_{i,i}$

$\hat{y}_i - \hat{y}_{i,i}$ IS $\frac{1}{1-S_{ii}(\hat{x}, \lambda)}$

$$(y_i - \hat{y}_{i,i}) = \frac{(y_i - \hat{y}_i)}{1-S_{ii}(\hat{x}, \lambda)}$$

LEADS, AGAIN, TO A REGRESSION

$$\text{LOOCV} = \frac{1}{n} \sum_{i=1}^n \frac{(y_i - \hat{y}_i)^2}{(1-S_{ii}(\hat{x}, \lambda))^2}$$

- REGRESSION

LOOCV → REPEAT FOR $S(\hat{x}, \lambda)_{ii} = e$ SO INSTEAD

. REGRESSION

WE GET ANOTHER ONE REGRESSION → THE PREDICTION

→ A PREDICTIVE MODEL WHICH IS NOT PREDICTIVE

LOOCV SQUARED ERROR FOR RIDGE

WE GET "AIDS" IN THE LAMBDA IS NOT PREDICTIVE

. PREDICTIVE

$$w = \frac{1}{n} \sum_{i=1}^n \frac{(y_i - \hat{y}_i)^2}{(1-S_{ii}(\hat{x}, \lambda))^2} - \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

$$S_{ii}(\hat{x}, \lambda) = 2 \downarrow \text{NOT}$$

PREDICTIVE MODEL → PREDICTIVE MODEL w → PREDICTIVE
. PREDICTIVE LOOCV → NOT PREDICTIVE

91

11. 1. 14

Now $S(\mathbf{x}, \lambda)$; it is known that with λ increasing, ridge optimism for $S(\mathbf{x}, \lambda)$ is λ -reducible.

More specifically, $\hat{\mathbf{y}}_i - \mathbf{x}_i^T \hat{\mathbf{w}}$ is λ -reducible.

As λ increases, $\hat{\mathbf{y}}_i - \mathbf{x}_i^T \hat{\mathbf{w}}$ is λ -reducible with respect to λ .

Ridge optimism λ is λ -reducible. As $\lambda \rightarrow \infty$, $\hat{\mathbf{y}}_i - \mathbf{x}_i^T \hat{\mathbf{w}}$ is λ -reducible.

Thus, as $\lambda \rightarrow \infty$, ridge optimism λ is λ -reducible.

Optimism $\lambda \rightarrow 0$ is λ -reducible. As $\lambda \rightarrow 0$, ridge optimism λ is λ -reducible.

Optimism $\lambda \rightarrow 0$ is λ -reducible. As $\lambda \rightarrow 0$, ridge optimism λ is λ -reducible.

$S_{ii}(\Sigma, \lambda) = 1$ if λ is optimism-reducible. Otherwise, $S_{ii}(\Sigma, \lambda) = 0$.

$S_{ii}(\Sigma, \lambda) = 1$ if λ is optimism-reducible. Otherwise, $S_{ii}(\Sigma, \lambda) = 0$.

$\lambda \rightarrow \infty$ is λ -reducible. $S(\Sigma, \lambda)$ is λ -reducible.

$$S(\Sigma, \lambda) = \sum (\Sigma^\top \Sigma + \lambda I)^{-1} \Sigma^\top$$

SVR \Rightarrow linear SSF

$$\Sigma_{pp} = U_{pp} D_{pp} V_{pp}^\top$$

$$\star \quad \Sigma^\top \Sigma = U^\top D^\top U \cdot U D V^\top = U^\top D^\top V^\top$$

$$\star \quad \Sigma^\top \Sigma + \lambda I = U^\top V^\top \cdot \lambda V V^\top = U^\top (D^\top \cdot \lambda I)^\top V^\top$$

$$\star \quad (\Sigma^\top \Sigma + \lambda I)^\top = \sqrt{\text{diag}\left(\frac{1}{\lambda_j + \lambda}\right)} V^\top$$

$$S(\Sigma, \lambda) = U^\top D^\top V^\top \cdot \sqrt{\text{diag}\left(\frac{1}{\lambda_j + \lambda}\right)} V^\top V D U^\top$$

M.1.14

5.2

$$= U D \cdot \text{diag} \left(\frac{1}{\lambda_j + \lambda} \right) D \cdot U^T$$

$$= U \cdot \underset{\text{hyp}}{\text{diag}} \left(\frac{\lambda_j^2}{\lambda_j^2 + \lambda} \right) \cdot \underset{\text{hyp}}{U^T}$$

$$= \begin{pmatrix} 1 & & & \\ u_1 & \dots & u_p \\ 1 & & 1 \end{pmatrix} \cdot \begin{pmatrix} \frac{\lambda_1^2}{\lambda_1^2 + \lambda} & & \\ & \ddots & \\ & & \frac{\lambda_p^2}{\lambda_p^2 + \lambda} \end{pmatrix} \begin{pmatrix} -u_1 \\ \vdots \\ -u_p \end{pmatrix}$$

$$\zeta(\Sigma, \lambda)_{ii} = \sum_{j=1}^p u_{ij}^2 \cdot \frac{\lambda_j^2}{\lambda_j^2 + \lambda}$$

10) $\zeta(\Sigma, \lambda)$ \rightarrow λ \in \mathbb{R} \setminus λ_i $\forall i$ \in $\{1, \dots, p\}$
 $\zeta(\Sigma, \lambda)$ \rightarrow λ \in \mathbb{R} \setminus λ_i $\forall i$ \in $\{1, \dots, p\}$

$$\frac{\partial \zeta(\Sigma, \lambda)_{ii}}{\partial \lambda} = \sum_{j=1}^p \frac{-u_{ij}^2 \cdot \lambda_j^2}{(\lambda_j^2 + \lambda)^2} < 0$$

λ \in \mathbb{R} \setminus λ_i $\forall i$ \in $\{1, \dots, p\}$
 $\zeta(\Sigma, \lambda)_{ii}$ \rightarrow λ \in \mathbb{R} \setminus λ_i $\forall i$ \in $\{1, \dots, p\}$

$$w = \frac{1}{n} \sum_{i=1}^n \frac{(y_i - \hat{y}_i)^2}{(1 - \zeta_{ii}(\Sigma, \lambda))^2} - \frac{1}{n} \sum_{i=1}^n (\hat{y}_i - \bar{y})^2$$

$$(1 - \zeta_{ii}(\Sigma, \lambda))^2 \quad \text{10.11.2021 10.11.2021} \quad \zeta_{ii}(\Sigma, \lambda) \quad \text{p. 1}$$

(11)

M. 1. 14

ר' 1)

|W|

ר' 2)

$$\frac{1}{n} \sum_{i=1}^n \frac{(y_i - \hat{y}_i)^2}{(1 - s_{ii}(\hat{\Sigma}, \lambda))}$$

ו אט פור (ונא שער פון) $S(\hat{\Sigma}, \lambda)$ אט ר' 1
 $S(\hat{\Sigma}, \lambda)_{ii}$ אט ר' 2

וילס מילא ניטרנו פור גודל פון וילס *

range(0, infinity) | λ אט פור גודל מילא -

λ כוונת פולס אט גודל מילא -

λ גודל train → וילס אט מילא מילא -

$$\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

λ גודל פוג לוכס אט מילא מילא -

$$\frac{1}{n} \sum_{i=1}^n \frac{(y_i - \hat{y}_i)^2}{(1 - s_{ii}(\hat{\Sigma}, \lambda))}$$

$w(\lambda)$; λ אט פור גודל מילא מילא -

$w(\lambda)$ גודל כוכב -

טבליות מילא פור גודל מילא מילא -

לוכס → פולס

$$GCV(\hat{\beta}) = \frac{1}{n} \sum_{i=1}^n \frac{(y_i - \hat{y}_i)^2}{(1 - tr(S)/n)}$$

לוססו מילא גודל מילא מילא (פ)

$$\hat{\beta}_{\text{Lasso}} = \arg \min_{\beta} \|y - X\beta\|^2 + \lambda \|\beta\|_1$$

מילא לוססו גודל מילא מילא פולס גודל מילא -

טבליות מילא פולס גודל מילא מילא מילא -

(ז)

29. 9. 19

p. 1

Yield per unit land, Lessor yield per unit land
- e.g. 'VRF' 'CNR'

$$\hat{y}_i = S(\Sigma) \cdot y_i$$

Lessor

KNN and linear VRF with Lessor yield function (f)

if x_i is closest point to Σ then y_i is the yield

f_{VRF}

KNN VRF

$$\hat{y}_i = \sum_{\substack{j=1 \\ j: x_j \in N_K(x_i)}}^N \frac{1}{K} \cdot y_j = S(\Sigma) \cdot y_i$$

$$\hat{y}_i = \begin{cases} \frac{1}{K} & \text{if } x_i \in N_K(x_i) \\ 0 & \text{else} \end{cases}$$

Now define weighted average yield in KNN per unit area

if x_i is closest point to Σ then y_i is the yield

so weighted average yield is the weighted average of yields

$$\hat{y}_i^{(e)} = \sum_{\substack{j=1 \\ j \neq i \\ j: x_j \in N_K(x_i)}}^N \frac{1}{K} \cdot y_j$$

x_i is closest point to Σ so y_i is the yield $\hat{y}_i^{(e)}$ is zero

but y_i is non-zero so i is closest point to Σ so $\hat{y}_i^{(e)}$ is non-zero

$$\hat{y}_i = \sum_{j=1}^N \frac{1}{K} \hat{y}_j = \sum_{\substack{j=1 \\ j \neq i \\ j: x_j \in N_K(x_i)}}^N \frac{1}{K} \cdot y_j + \frac{1}{K} \hat{y}_i^{(e)}$$

(1)

10.1.19

Einige Beispiele für KNN und mKNN

$$\hat{y}_i = \hat{y}_i^{(1)}$$

$$x = \begin{pmatrix} 1 \\ 2 \\ 4 \end{pmatrix} \quad y = \begin{pmatrix} 0 \\ 50 \\ 100 \end{pmatrix}$$

1. KNN
KNN mit $k=2$

; $j=2$ ist die 2. Nächste Nachbar

$$\hat{y}_2^{(1)} = \sum_{\substack{j=1 \\ j \neq 2}}^3 \frac{1}{2} y_j = \frac{1}{2} \cdot 0 + \frac{1}{2} \cdot 100 = 50$$

$j \mid x_j \in \mathcal{N}_2(x_i)$

$$\tilde{x} = \begin{pmatrix} 1 \\ 2 \\ 7 \end{pmatrix} \quad \tilde{y} = \begin{pmatrix} 0 \\ 50 \\ 100 \end{pmatrix}$$

2. KNN mit $m=2$

$$\hat{y}_2^{(2)} = \sum_{j=1}^3 \frac{1}{2} \cdot \tilde{y}_j = \frac{1}{2} \cdot 50 + \frac{1}{2} \cdot 0 = 25$$

$j \mid x_j \in \mathcal{N}_2(x_i)$

$$\hat{y}_i \neq \hat{y}_i^{(1)}$$

KNN unterscheidet sich von mKNN

$$P \geq n, \quad X_{n \times p}$$

full rank $\Rightarrow \text{rank}(X) = n \quad (\text{a})$

full rank \Rightarrow $X^T X$ is invertible \Rightarrow $X^T X^{-1} X = I_p$
 $\Rightarrow X^T X^{-1} X = I_p$ \Rightarrow $X^T X^{-1}$ is full rank

$$\text{rank}(X) = \min(n, p) = n$$

Now we can use the normal equation to find $\hat{\beta}$

for simple linear regression we have

$$y = X\beta \quad / \quad L(y_i, \hat{y}_i) = \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

for minimum $L(\cdot)$ we have to find $\hat{\beta}$ such that

$\hat{\beta}$ is the unique solution of

minimize $L(\cdot)$ over all β in \mathbb{R}^p

from $\hat{y}_i = \beta_0 + \beta_1 x_{i1} + \dots + \beta_p x_{ip} = y_i$

training set \rightarrow y_i vs x_{i1}, \dots, x_{ip}

new point (x_0, y_0) \rightarrow y_0 vs x_{01}, \dots, x_{0p}

new point (x_0, y_0) \rightarrow y_0 vs x_{01}, \dots, x_{0p}

$$\hat{y}_i = \beta_0 + \beta_1 x_{i1} + \dots + \beta_p x_{ip} = y_i$$

new point $\hat{y}_i = y_i$ \rightarrow y_i vs x_{i1}, \dots, x_{ip}

new point $\hat{y}_i = y_i$ \rightarrow y_i vs x_{i1}, \dots, x_{ip}

$$\sum_{i=1}^n (y_i - \hat{y}_i)^2 = \sum_{i=1}^n (y_i - \beta_0 - \beta_1 x_{i1} - \dots - \beta_p x_{ip})^2 = 0$$

new point $\hat{y}_i = y_i$ \rightarrow y_i vs x_{i1}, \dots, x_{ip} (i)

new point $\hat{y}_i = y_i$ \rightarrow y_i vs x_{i1}, \dots, x_{ip}

new point $\hat{y}_i = y_i$ \rightarrow y_i vs x_{i1}, \dots, x_{ip}

(23)

11.1.19

P+1 תר מילון נס רה מילון מוד ל' יי' ג' ג' ג' ג' ג' ג'

מילון מילון סדר מילון פסנ רה' פסנ רה' פסנ רה'

יק כוונת פסנ רה' ג' ג'

פ' ג' ג'

פ' ג' ג'

פ' ג' ג'

פ' ג' ג'

פ' ג' ג'

$$\text{cond.} \sum_{i=1}^n |y_i - \hat{y}_i| = \sum_{i=1}^n |y_i - \hat{y}_i| = 0$$

$$\text{prf.} \sum_{i=1}^n \gamma(y_i - \hat{y}_i) + \sum_{i=1}^n -(1-\gamma)(y_i - \hat{y}_i) = 0$$

$$\therefore y_i \geq \hat{y}_i \quad \text{if } y_i < \hat{y}_i$$

'ridge' on 'you' (b)

$$\min_{\beta_0, \beta} \sum_{i=1}^n (y_i - \hat{y}_i)^2 + \lambda \sum_{j=1}^p \beta_j^2$$

ג' אפ' נס פ' ג' ג'

. אפ' נס פ' ג' ג'

; א; ג' ג'

$$\frac{\partial \left(\sum_{i=1}^n (y_i - \hat{y}_i)^2 + \lambda \sum_{j=1}^p \beta_j^2 \right)}{\partial \beta_j} \Bigg|_{\hat{y}'(\lambda)} = 0$$

ג' ג'

$$2 \sum_{i=1}^n (y_i - \hat{y}_i)^2 \cdot x_{ij} + 2\lambda \beta_j \Bigg|_{\hat{y}'(\lambda)} = 0$$

(24)

לעומת הדרישות המודרניות, מושג זה מושג על ידי מילויו של אחד מהתפקידים המרכזיים של הדת, תרבות הדת, שפירושו בפועל מילויו של תפקידו של הדת כSubsystem חברתי-תרבותי.

$$\sum_{i=1}^n (y_i - \hat{y}_{\text{inter}} - \hat{\beta}_0 - \hat{\beta}_j) \cdot x_{ij} + \lambda \hat{\beta}_j$$

$$y_i = y_i$$

>0

$$= 2 \cdot \sum_{i=1}^n (\gamma_i - \hat{\beta}_i) x_{ij} + 2\lambda \hat{\beta}_{\text{inter}} = 2\lambda \hat{\beta}_{\text{inter}} + 0$$

$$f^{(n)}(z) = \sum_{k=0}^n \frac{f^{(k)}(z_0)}{k!} (z-z_0)^k$$

ללא מושג של אמצעים כלכליים או טכנולוגיים, לא ניתן למסור מושג של אמצעים כלכליים או טכנולוגיים.

$$\hat{\beta}(N) \neq \hat{\beta}_{\text{intr}}$$

$$\hat{\beta}^1(z) = \arg \min_{\beta_j} \sum_{j=1}^p \beta_j^2$$

17

$$\leq \left(y_i - x_i^T \beta - \beta_0 \right)^2 = 0$$

$$L(\lambda) = \sum_{i=1}^n \left(y_i - x_i^\top \beta - \beta_0 \right)^2 + \lambda \sum_{j=1}^p \beta_j^2$$

$$\langle(\lambda)\rangle = \sum_{i=1}^n \left(y_i - \lambda_i^T \beta - \rho_i \right)^2 + \lambda \sum_{i=1}^n \beta_i^2 \quad \text{Subject to} \quad \sum_{i=1}^n (y_i - \lambda_i^T \beta - \rho_i)^2 = 0$$

M.T. 19

NONLINEAR REGRESSION: NON-LINEAR LEAST SQUARES

$$\mathcal{L}(\lambda) = \sum_{i=1}^n (y_i - \hat{y}_i)^2 \quad \text{s.t. } \lambda \leq \beta_j$$

$$y_i = \hat{y}_i$$

$$\text{s.t. } \sum_{i=1}^n (y_i - \hat{y}_i)^2 \beta_j - \beta_0 = 0$$

MINIMIZE THE SUM OF SQUARES

$$\min_{\beta} \sum_{j=1}^n \lambda \leq \beta_j = \min_{\beta} \sum_{j=1}^n \beta_j \quad \text{s.t. } \sum_{i=1}^n (y_i - \hat{y}_i)^2 \beta_j - \beta_0 = 0$$

MINIMIZE THE SUM OF SQUARES

MINIMIZE THE SUM OF SQUARES

$$\hat{\beta}(\lambda) \rightarrow \hat{\beta}^{(1)} \quad \text{as } \lambda \rightarrow 0$$

MINIMIZE THE SUM OF SQUARES

$\lambda \rightarrow 0$ THE SLOPES j BECOME $2\lambda \beta_j + 0 = 0$

$\hat{\beta}(0)$ WHEN j BECOME $2\lambda \beta_j \rightarrow 0$ AS $\lambda \rightarrow 0$

MINIMIZE THE SUM OF SQUARES

$$\hat{\beta}(\lambda) = \arg \min_{\beta, \beta_0} \sum_{i=1}^n (y_i - \hat{y}_i)^2 \quad \text{s.t. } \lambda \leq \beta_j$$

MINIMIZE THE SUM OF SQUARES

MINIMIZE THE SUM OF SQUARES

$$\sum_{i=1}^n (y_i - \hat{y}_i)^2 \beta_j - \beta_0 = 0$$

MINIMIZE THE SUM OF SQUARES

$$\hat{\beta}(\lambda) = \underset{\lambda \rightarrow 0}{\text{argmin}} \sum_{j=1}^p \beta_j^2$$

s.t. $\sum_{i=1}^n (y_i - x_i^\top \beta - \beta_0)^2 = 0$

thus $\lambda \rightarrow 0$ when $\lambda \leq \beta_j$ all terms β_j^2 are zero and thus

$$\hat{\beta}(\lambda) = \underset{\lambda \rightarrow 0}{\text{argmin}} \sum_{j=1}^p \beta_j^2$$

s.t. $\sum_{i=1}^n (y_i - x_i^\top \beta - \beta_0)^2 = 0$

$\hat{\beta}^{(k)}$ at step k is as follows

$$\hat{\beta}(\lambda) \rightarrow \hat{\beta}^{(k)}$$

$\lambda \rightarrow 0$

$\hat{\beta}^{(k)}$ is the solution to (1)

$$\hat{\beta}^{(k)} = \underset{\lambda \rightarrow 0}{\text{argmin}} \sum_{j=1}^p \beta_j^2$$

s.t. $\sum_{i=1}^n (y_i - x_i^\top \beta - \beta_0)^2 = 0$

Kernel representation of ridge regression

SVD representation for step k is $(U_k V_k^\top + \lambda I_n)$

thus $U_k^\top \beta^{(k)} = U_k^\top (U_k V_k^\top + \lambda I_n) \beta^{(k)} = V_k^\top \beta^{(k)} + \lambda U_k^\top \beta^{(k)}$

and $U_k^\top \beta^{(k)} = U_k^\top \beta^{(k-1)} + \lambda U_k^\top \beta^{(k)}$ since $\text{rank } U_k = n$ and X is $n \times p$

$$\hat{\beta}(\lambda) = \tilde{X}^\top (\tilde{X} \tilde{X}^\top + \lambda I_n)^{-1} Y$$

ridge

1) $\hat{\beta}(\lambda)$ $\hat{\beta}(0)$

$$\hat{\beta}(\lambda) \xrightarrow[\lambda \rightarrow 0]{} \hat{\beta}^{(1)}$$

$$\lim_{\lambda \rightarrow 0} \hat{\beta}(\lambda) = \lim_{\lambda \rightarrow 0} \hat{\beta}^{(1)}(\lambda) = \lim_{\lambda \rightarrow 0} \left(\sum_i \left(\sum_j \hat{x}_j^T - \lambda I_n \right)^{-1} y_i \right)$$

$$= \sum_i \left(\sum_j \hat{x}_j^T \right)^{-1} y_i = \hat{\beta}^{(1)}$$

לפיה $\hat{\beta}^{(1)}$ מוגדרת כפונקציית ראנק n

$$\text{def } \hat{\beta}^{(1)} \quad \text{לפיה } \hat{\beta}^{(1)} \text{ מוגדרת כפונקציית ראנק}$$

$$\min_{j=1}^n |\beta_j|$$

$$\text{s.t. } \sum_i (y_i - \hat{x}_i^T \hat{\beta} - \beta_0)^2 = 0$$

לפיה $\hat{\beta}^{(1)}$ מוגדרת כפונקציית ראנק מוגדרת כפונקציית ראנק

לפיה

לפיה $\hat{\beta}^{(1)}$ מוגדרת כפונקציית ראנק מוגדרת כפונקציית ראנקלפיה $\hat{\beta}^{(1)}$ מוגדרת כפונקציית ראנק מוגדרת כפונקציית ראנק

$$\hat{\beta}^{(1)} \xrightarrow[\lambda \rightarrow 0]{} \hat{\beta}^{(1)}$$

$\hat{\beta}^{(1)}$ מוגדרת כפונקציית ראנק מוגדרת כפונקציית ראנק

$$\hat{\beta}_{\text{arg}}^{(1)} = \arg \min_{\beta} \sum_{j=1}^n |\beta_j|$$

$$\text{s.t. } \sum_i |y_i - \hat{x}_i^T \beta - \beta_0| = 0$$

(2)

$$\hat{\beta}_{\text{out}}^{(1)} = \arg \min \sum_{j=1}^p |\beta_j|$$

$$\text{s.t. } \sum_{i=1}^n \gamma(y_i - \hat{y}_i) + \sum_{i=1}^n (1-\gamma)(y_i - \hat{y}_i) = 0$$

$$\therefore y_i \geq \hat{y}_i \quad \therefore y_i < \hat{y}_i$$

∴ L1S वित्तीय लासो फूले

$$\begin{array}{c} \hat{\beta}(\lambda) \\ \text{abs} \end{array} \xrightarrow[\lambda \rightarrow 0]{} \hat{\beta}_{\text{LSS}}^{(1)} \quad / \quad \begin{array}{c} \hat{\beta}(\lambda) \\ \text{out} \end{array} \xrightarrow[\lambda \rightarrow 0]{} \hat{\beta}_{\text{out}}^{(1)}$$

(9)

का जो पुराना फूले परिप्रेक्षा फूले सुनिश्चित हो जाएगा (i)
 इसमें लासो का विनाश λ का विनाश

मात्र फूले मात्र लासो \rightarrow फूले रिट्रैट \rightarrow फूले डॉर्ट

$0 \sim \sigma$

!(constraint लासो) \rightarrow लासो

$S \rightarrow \infty$

फूले मात्र लासो \rightarrow फूले रिट्रैट \rightarrow फूले डॉर्ट
 $0 \sim \sigma$ लासो

लासो का अधिक फूले लासो फूले लासो लासो लासो

लासो लासो लासो लासो लासो लासो लासो

लासो लासो लासो लासो लासो लासो लासो

रिट्रैट

(10)

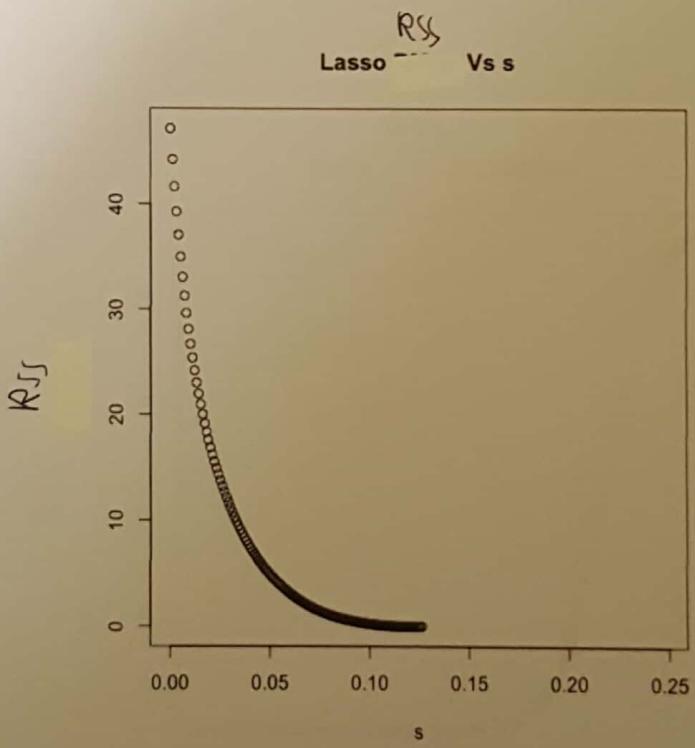
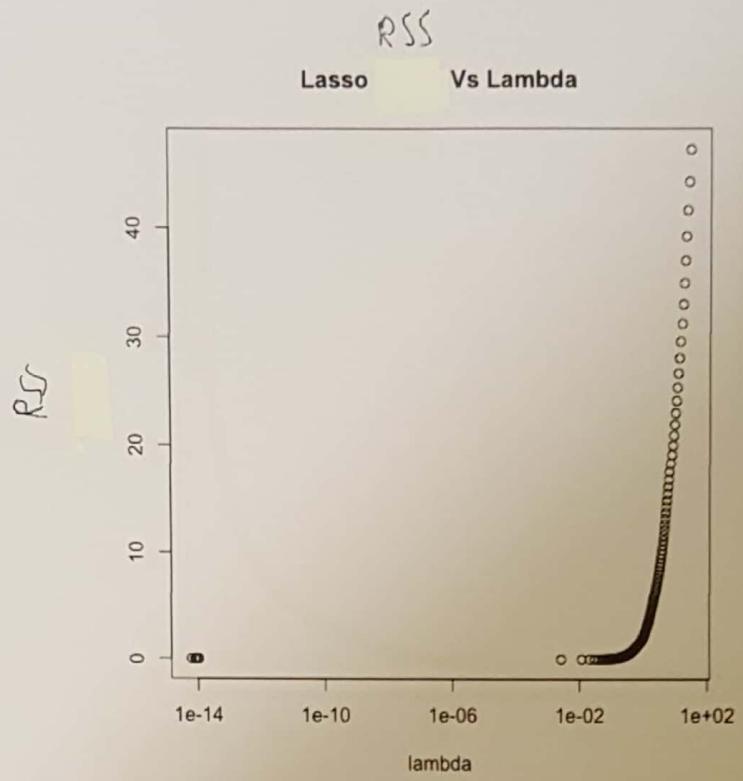
L1 norm for Lasso: 6.5102

L1 norm for ridge: 8.4917

L2 norm for Lasso: 2.6726

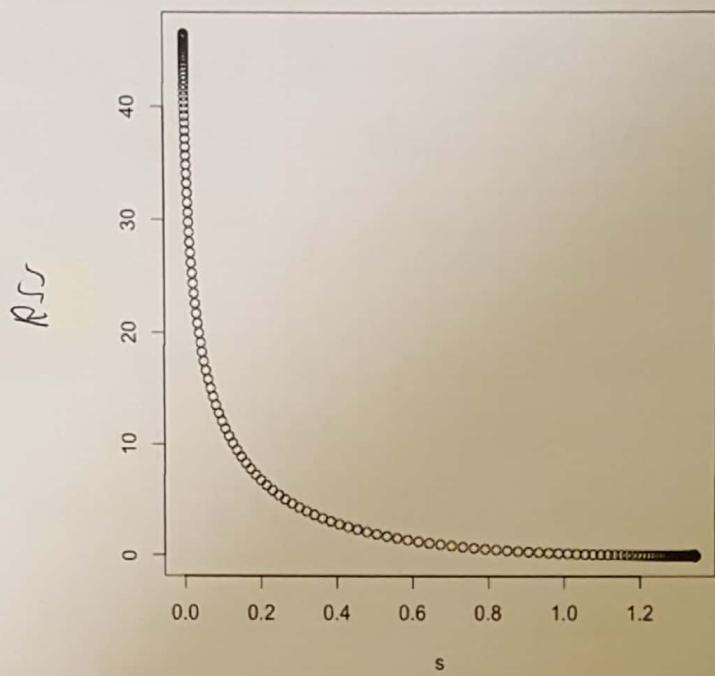
L2 norm for ridge: 1.344

(11)

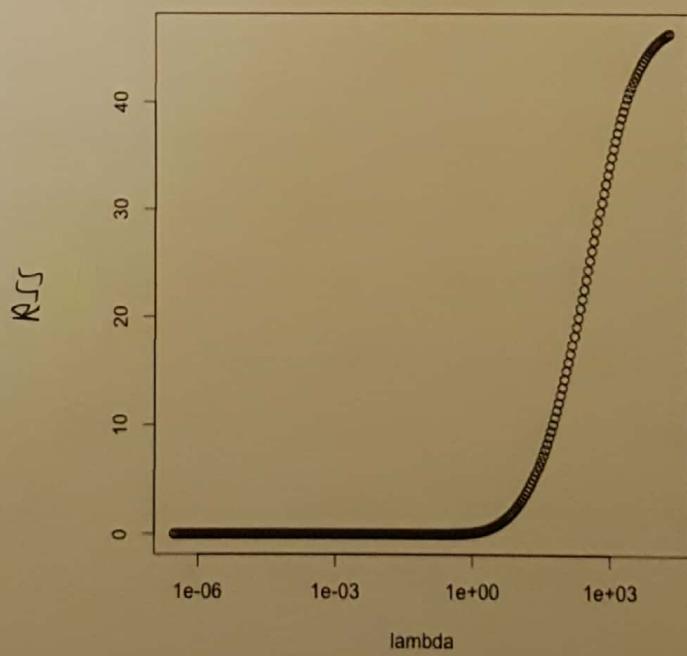


(30)

Ridge | RSS
Vs s



Ridge | RSS
Vs Lambda



(31)

12.1.19

12

בנין Ridge כב L1 מינימיזציה (לעומת Ridge) שמהם נובעת מושג

בנין Ridge כב L1 מינימיזציה Ridge כב L1 מינימיזציה Ridge

בנין Ridge כב L1 מינימיזציה Ridge כב L1 מינימיזציה Ridge

בנין Ridge כב L1 מינימיזציה Ridge כב L1 מינימיזציה Ridge

$$\beta^{(1)} \quad | \quad \beta^{(2)}$$

ונז $\lambda \rightarrow 0$ -> גבול בOUND כב פאראמיטר ליניארי $\lambda \rightarrow 0$

בנין Ridge כב L1 מינימיזציה Ridge כב L1 מינימיזציה Ridge

norm. val = 0.45 \Rightarrow (1) (2) (3) (4)

בנין Ridge כב L1 מינימיזציה Ridge כב L1 מינימיזציה Ridge (ה)

בנין Ridge כב L1 מינימיזציה Ridge כב L1 מינימיזציה Ridge

בנין Ridge כב L1 מינימיזציה Ridge כב L1 מינימיזציה Ridge (ה)

בנין Ridge כב L1 מינימיזציה Ridge כב L1 מינימיזציה Ridge (ה)

בנין Ridge כב L1 מינימיזציה Ridge כב L1 מינימיזציה Ridge (ה)

בנין Ridge כב L1 מינימיזציה Ridge כב L1 מינימיזציה Ridge (ה)

בנין Ridge כב L1 מינימיזציה Ridge כב L1 מינימיזציה Ridge (ה)

בנין Ridge כב L1 מינימיזציה Ridge כב L1 מינימיזציה Ridge (ה)

sum -> פונקציית פגיעה מינימלית. (margin maximizing hyperplane)

ונז פונקציית פגיעה מינימלית. (margin maximizing hyperplane)

לפיה מינימום

$$\min_{\beta} \|\beta\|_1$$

$$s.t. y_i (\beta^\top \beta + \rho_0) \geq 1$$

בנין Ridge כב L1 מינימיזציה Ridge כב L1 מינימיזציה Ridge

(2)

use margin γ_i and $\|\beta\|_2^2$ de margins from p'th norm

1,1 regularized L2

$$y_i (\mathbf{x}_i^\top \beta + \beta_0) \geq 1$$

then find the max γ_i and $\|\beta\|_2^2$

Separable case \rightarrow 's margin γ_i & $\|\beta\|_2^2$ is fixed -

LOSS FUNCTION OR LOSS FUNCTION ($\rho \geq 0$ LOSS FUNCTION)

w/p ridge

$$\hat{\beta}(\lambda) = \arg \min_{\beta} -l(\beta; \lambda, y) + \lambda \|\beta\|_2^2$$

where $l(\beta; x, y)$ is logistic log likelihood

$$\frac{\hat{\beta}(\lambda)}{\|\hat{\beta}(\lambda)\|_2} \rightarrow \text{Ridge} \quad \lambda \rightarrow 0 \quad \text{L2}$$

SVN function

\rightarrow margin function margin function w/o loss

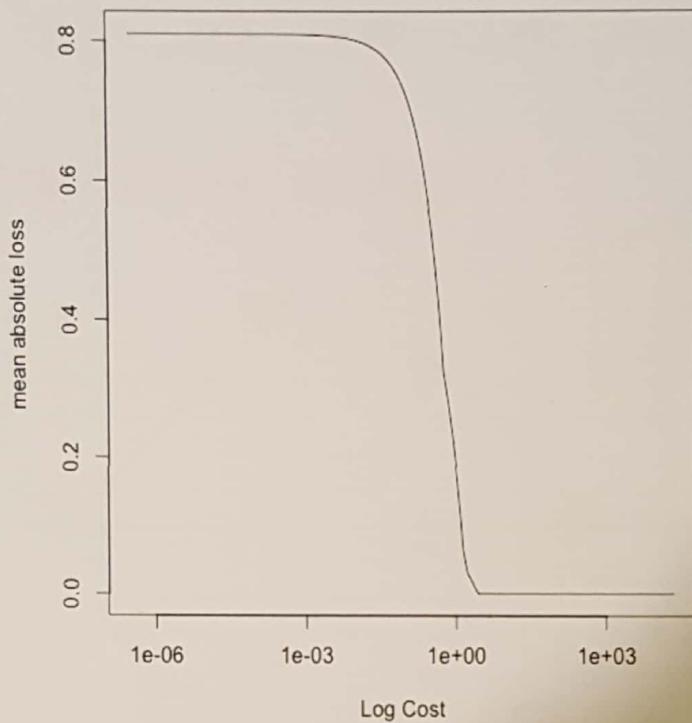
$$\frac{\hat{\beta}(\lambda)}{\|\hat{\beta}(\lambda)\|_2} \xrightarrow{\lambda \rightarrow 0} \text{SVM} = \text{minimum-hyper-interpolation}$$

RE SVM problem $\rightarrow \hat{\beta}^{(0)}$ & w/o loss function w/o loss

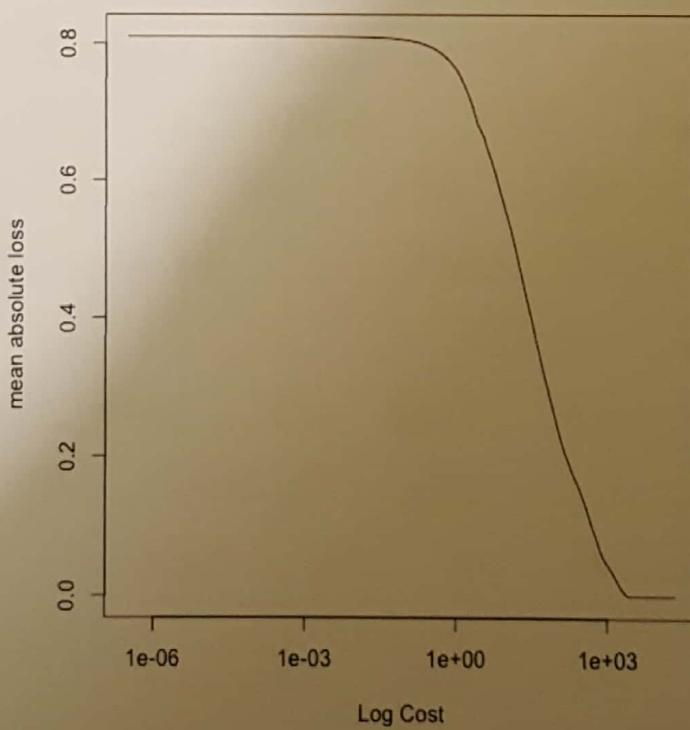
loss function w/o loss function w/o loss

$$\frac{\hat{\beta}(\lambda)}{\|\hat{\beta}(\lambda)\|_2} \xrightarrow{\lambda \rightarrow 0} \text{L2}, \quad \hat{\beta}^{(0)} \& \text{L2}$$

Support vector regression-RBF kernel Gamma=5.0



Support vector regression-RBF kernel Gamma=0.0001

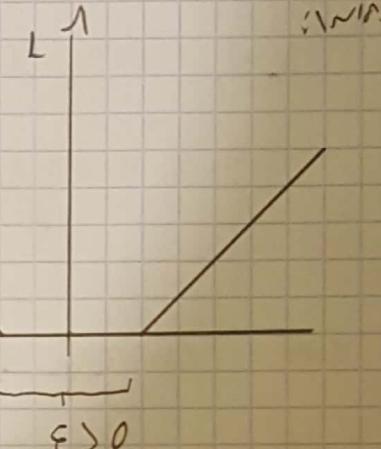
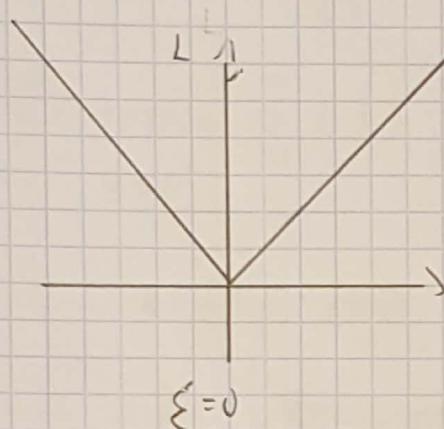


(24)

Absolute loss kernel regression.

Prob. 11 type = "pls-regression" - / $\epsilon=0$ und -
in der Praxis wird $\epsilon>0$

$$\|y - f(x)\|_{\epsilon} = \max_{\epsilon} \{0, \|y - f(x)\|_1 - \epsilon\}$$



$\|y - f(x)\|_{\epsilon} = \max_{\epsilon} \{0, \|y - f(x)\|_1 - \epsilon\}$

$$\|y - f(x)\|_{\epsilon} = \max_{\epsilon} \{0, \|y - f(x)\|_1 - \epsilon\} = \|y - f(x)\|_1$$

Maximal Fehlermaß Punktmaß Mindest Fehlermaß -

Maximal Fehlermaß 0 Punktmaß Mindest Fehlermaß -

(Minimax Fehlermaß Mindest Fehlermaß Mindest Fehlermaß -)

Minimax Fehlermaß Mindest Fehlermaß Mindest Fehlermaß -

Minimax Fehlermaß

Minimax Fehlermaß Mindest Fehlermaß Mindest Fehlermaß -

Minimax Fehlermaß Mindest Fehlermaß Mindest Fehlermaß -

Minimax Fehlermaß Mindest Fehlermaß Mindest Fehlermaß -

$$f(y) = \sum_{k=1}^n \beta_k h_k(x)$$

$$\|f\|_{H_K}^2 = \sum_{k=1}^n \beta_k^2$$

Minimax Fehlermaß

Minimax Fehlermaß Mindest Fehlermaß (35)

$$\hat{f} = \operatorname{argmin}_{f \in \mathcal{H}_K} \sum_{i=1}^n L(y_i, f(x_i)) + \lambda \sum_{k=1}^K \beta_k^2$$

Now we have to find the function f which is \hat{f} .

$$\hat{f}_\lambda(\underline{x}) = \sum_{i=1}^n \alpha_i K(\underline{x}, \underline{x}_i)$$

Now we can consider the function \hat{f}_λ .

$$\hat{f} = \operatorname{argmin}_{\alpha \in \mathbb{R}^n} \sum_{i=1}^n L(y_i, \sum_{j=1}^n \alpha_j K(\underline{x}_i, \underline{x}_j)) + \lambda \sum_{k=1}^K \alpha_k^2$$

$$K = [K_{ij}] = [K(\underline{x}_i, \underline{x}_j)] \quad (\text{is } K \text{ is symmetric and})$$

Now we have to find the value of α . We can use the formula $\alpha = K^{-1} y - K^{-1} b$. This is called the normal equation.

- Prediction for small gamma is: 3.365144 (iii)

- Prediction for Big gamma is: 3.589935

Now we have to find the value of γ . Now we know that $\gamma = \frac{1}{2\sigma^2}$

Now we have to find the value of γ .

$$K(\underline{x}, \underline{x}^*) = e^{-\gamma \sum_{m=1}^p (x_{im} - x_m^*)^2}$$

$$\gamma = \frac{1}{2\sigma^2}$$

(iv)

Now we have to find the value of γ .

Now we have to find the value of γ .

$$f(\underline{x}^*) = \sum_{i=1}^n \alpha_i K(\underline{x}^*, \underline{x}_i)$$

(iv)

(36)

17.9.18

11

ה) (6) \hat{Y} סט וריאנט, $\hat{Y} = \beta_0 + \beta_1 X_1 + \dots + \beta_n X_n$ פונקציית מינימיזציה (least squares)

(i) גודל $\hat{\sigma}_u^2 = S_{uu} = \frac{1}{n-2} \sum_{i=1}^n (y_i - \hat{y}_i)^2$

ב) \hat{Y} סט וריאנט, פונקציית מינימיזציה (least squares)

.(f) \hat{Y} סט וריאנט

ג) \hat{Y} סט וריאנט, פונקציית מינימיזציה (least squares)

ה) \hat{Y} סט וריאנט, פונקציית מינימיזציה (least squares)

ו) \hat{Y} סט וריאנט, פונקציית מינימיזציה (least squares)

פ) \hat{Y} סט וריאנט, פונקציית מינימיזציה (least squares)

Basis \hat{Y} סט וריאנט

ה) \hat{Y} סט וריאנט, פונקציית מינימיזציה (least squares)

ג) \hat{Y} סט וריאנט, פונקציית מינימיזציה (least squares)

ה) \hat{Y} סט וריאנט, פונקציית מינימיזציה (least squares)

ו) \hat{Y} סט וריאנט, פונקציית מינימיזציה (least squares)

0.8423 (1) \hat{Y} סט וריאנט, פונקציית מינימיזציה (least squares)

ג) \hat{Y} סט וריאנט, פונקציית מינימיזציה (least squares)

ה) Basis \hat{Y} סט וריאנט, פונקציית מינימיזציה (least squares)

ו) Basis \hat{Y} סט וריאנט, פונקציית מינימיזציה (least squares)

ה) Basis \hat{Y} סט וריאנט, פונקציית מינימיזציה (least squares)

ו) Basis \hat{Y} סט וריאנט, פונקציית מינימיזציה (least squares)

(3.36 מילון נורמה פונקציית מינימיזציה (least squares))

ה) Basis \hat{Y} סט וריאנט, פונקציית מינימיזציה (least squares)

ו) Basis \hat{Y} סט וריאנט, פונקציית מינימיזציה (least squares)

ה) Basis \hat{Y} סט וריאנט, פונקציית מינימיזציה (least squares)

(3)

13.1.14

22

Perhap vil vi se os nu igen på lørdag

Ønsker du at jeg skal komme til lørdag?

$$\hat{y}_i \approx 3.59$$